

EVALCASE 02

Retrieval & Temporal Context

Systemevaluation av informationshämtning och temporal kontext

STATUS	TESTTYP
Genomfört portfolio-case	Simulerad systemevaluation av retrieval och answer generation
DOMÄN	TESTDATUM
Account management / företagsinformation över tid	September 2026

Snabb översikt

Kontrollpunkt	Resultat
Retrieval-test	8/8 godkända
Answer generation	8/8 godkända
Stale retrieval	0
Cross-customer contamination	0
Kritiska svarsfel	0

TESTAD SYSTEMKEDJA

Fråga → Retrieval → Begränsad kontext → Answer generation

1. Syfte

Syftet var att testa om ett AI-baserat informationssystem kan identifiera och använda rätt information när ett historiskt underlag innehåller:

- äldre och nyare uppgifter,
- interna prognoser och faktiska kundbeslut,
- tillfälliga och permanenta tillstånd,
- information om flera olika kunder,
- förändringar i projektstatus,
- tekniska godkännanden som inte motsvarar kommersiella beslut.

Tidigare test visade att modellen kunde resonera korrekt när relevant information redan fanns direkt i kontexten. Evalcase 02 flyttade därför fokus till själva informationshämtningen.

Evalen separerade två delar:

RETRIEVAL	ANSWER GENERATION
Hämtar systemet rätt underlag?	Använder modellen det hämtade underlaget korrekt?

2. Testmiljö

Ett simulerat historiskt account-underlag skapades för företaget Nordmark Systems AB och kunden Fjordtek AB. Materialet bestod av 40 kronologiska anteckningar, B1–B40, från januari till september 2026. Underlaget kombinerade kundbesked, interna prognoser, supporthändelser, kontaktförändringar, CRM-status, projektbeslut och information om flera kunder. Materialet konstruerades så att aktuell status i flera fall krävde att äldre information vägdes mot senare uppdateringar.

3. Systemkedja

Evalen separerade systemet i två steg:



Retrieval-komponenten fick hela B1–B40 och valde högst fyra relevanta dokument utan att besvara frågan. Answer-komponenten fick endast frågan och de dokument som retrieval-steget valt. Den hade inte tillgång till hela B1–B40. Därmed kunde två feltyper skiljas åt:

RETRIEVAL-FEL avgörande information når inte modellen.	ANSWER-FEL rätt information finns i kontexten men används felaktigt.
--	--

4. Retrieval-test

Åtta frågor användes.

ID	Testfråga	Vald kontext	Resultat
R01	Aktuell status för Fjordteks AI-pilot	B31, B32, B34, B35	Godkänd
R02	CRM för supportplanering 2026	B8, B19, B24	Godkänd
R03	Aktuell primär operativ kontakt	B10, B24, B37	Godkänd
R04	Beslut om HubSpot-byte	B4, B8, B19, B24	Godkänd
R05	Om AI-piloten är vunnen efter security approval	B31, B32, B34, B35	Godkänd
R06	Johans långsamma svar som permanent problem	B15, B16	Godkänd
R07	Kund med faktiskt beställd AI-pilot och CRM	B38	Godkänd
R08	Senaste aktiva användarantal	B40	Godkänd

Retrieval-resultat

Godkända retrieval-fall: 8/8

Resultat: 8/8 retrieval-fall godkända. Inga fall av stale retrieval, cross-customer contamination eller saknad avgörande information observerades.

7. Vad evalen testade

Caset omfattade bland annat:

Temporal precedence senare giltig information ska kunna ersätta äldre status.	Discussed vs decided diskussioner och prognoser ska inte behandlas som beslut.
State vs trait tillfälliga tillstånd ska inte göras permanenta.	Source authority explicita kundbesked ska väga tyngre än interna prognoser.
Cross-customer boundaries information får inte läcka mellan kunder.	Approval-state separation tekniskt godkännande, budgetbeslut och faktisk beställning måste hållas isär.

8. Metodisk observation

Ett AI-system kan ha en stark språkmodell men ändå ge fel svar om retrieval-steget hämtar gammal, irrelevant eller ofullständig information.

Systemevaluation bör därför skilja mellan två frågor:

- 1 Hämtades rätt information?
- 2 Användes den hämtade informationen korrekt?

Separationen gör det möjligt att lokalisera felet i systemkedjan i stället för att enbart bedöma slutsvaret.

9. Begränsningar

Detta var inte ett produktions-RAG-test.

Retrieval-komponenten bestod av en språkmodell som fick ett litet, kontrollerat material B1–B40 direkt i kontexten.

Testet omfattade inte verklig vektorsökning, embeddings, chunking, reranking, metadatafilter, stora dokumentvolymmer eller produktionsmässiga access controls.

Resultatet ska därför inte beskrivas som bevis på prestanda hos ett kommersiellt RAG-system.

Caset demonstrerar i stället en kontrollerad metod för att separera retrieval-kvalitet från answer-kvalitet.

10. Kompetens som arbetsprovet demonstrerar

Arbetsprovet demonstrerar förmåga att definiera ett AI-kvalitetsproblem, konstruera en kontrollerad eval, separera retrieval från answer-generation, genomföra isolerade testkörningar och analysera resultaten.

Det demonstrerar även förståelse för mer subtila AI-kvalitetsproblem som:

- temporal viktning,
- stale context,
- diskuterat kontra beslutat,
- tillfälligt kontra permanent,
- informationsgränser mellan kunder,
- aktuell status kontra historisk prognos.

EVALGRÄNS

CASE	Detta är ett simulerat portfolio- och träningscase.
FÖRETAG / HÄNDELSER	Företagen, kunderna och affärshändelserna i underlaget är fiktiva.
RETRIEVALMILJÖ	Retrievalmiljön är simulerad.
GENOMFÖRANDE	Evaldesignen, retrieval-körningarna, de isolerade answer-körningarna och de redovisade resultaten genomfördes däremot faktiskt inom den beskrivna testmiljön.
TOLKNING	Resultaten ska inte tolkas som prestandamätning av ett verkligt kommersiellt AI- eller RAG-system.