

EVALCASE 03

Golden Set, Retrieval & Error Analysis

Systemevaluation av retrieval quality, source authority och answer generation

STATUS Genomfört portfolio-case	TESTTYP Kontrollerad eval av retrieval och answer generation
DOMÄN SaaS / policy-, avtals- och kundinformation	TESTDATUM September 2026

Snabb översikt

Dataset	Omfattning	Resultatmått	Utfall
Golden Set	45 frågor	TF-IDF Hit@3	12/15 (80 %)
Retrieval-test	15 frågor	TF-IDF Hit@5	13/15 (86,7 %)
Corpus	50 dokument	TF-IDF All Gold Sources @5	7/15 (46,7 %)
Primärkällor	18	Answer PASS	15/15
Distraktorer	32	Critical failures	0

TESTAD SYSTEMKEDJA

Fråga → Retrieval (TF-IDF / Embeddings) → Top 5 dokument → Begränsad kontext → Answer generation → Eval

1. Syfte och testdesign

Syftet med evalcasen är att undersöka hur ett AI-system hanterar frågor där korrekt svar kräver att systemet hittar rätt dokument, väger källor med olika auktoritet och tolkar tidsmässig och kundspecifik kontext korrekt.

Caset separerar två delar av systemets beteende:

RETRIEVAL QUALITY vilka dokument som hämtas för en fråga.	ANSWER QUALITY hur modellen använder de dokument som faktiskt har hämtats.
--	---

Testerna fokuserar särskilt på situationer där information kan vara korrekt men ändå olämplig att använda, exempelvis äldre policyversioner, ej accepterade utkast, interna anteckningar, kundspecifika avtal och historiska exempel.

2. Dataset

Evalcasen bygger på ett manuellt konstruerat testunderlag för det fiktiva SaaS-företaget Sundby Cloud.

GOLDEN SET G01–G45	PRIMÄRKÄLLOR S1–S18	CORPUS 50 dokument	DISTRAKTORER D01–D32
-----------------------	------------------------	-----------------------	-------------------------

Golden Set innehåller frågor inom bland annat källauktorit, temporal kontext, kundspecifika villkor, avstående vid otillräcklig evidens och risk för felaktig generalisering.

Distraktorerna är avsiktligt utformade för att likna relevanta källor och omfattar exempelvis äldre policyer, preliminära dokument, interna prognoser, marknadsmaterial, historiska kundfall och dokument från andra kunder.

3. Retrieval-metod

Som första baseline användes en enkel TF-IDF-baserad textsökning. Därefter genomfördes samma retrieval-test med en multilingual embedding-modell för att jämföra lexikal och semantisk retrieval på samma frågor och samma dokumentcorpus.

För varje fråga rangordnades samtliga 50 dokument och de fem högst rankade dokumenten hämtades. Retrieval-prestandan mättes med:

Hit@3	Hit@5
All Gold Sources @5	Missing Gold Sources

Det striktare måttet All Gold Sources @5 användes för att identifiera situationer där minst en relevant källa hittades men där en eller flera beslutsavgörande källor saknades.

4. Answer evaluation

För varje test skapades därefter en isolerad prompt som endast innehöll frågan och de fem dokument som retrieval-systemet hade hämtat.

Answer-resultatet bedömdes utifrån om modellen använde den faktiskt tillgängliga retrieval-kontexten korrekt. Ett test kunde därför få PASS även när en gold source saknades, om modellen korrekt identifierade att underlaget inte räckte för en säkrare slutsats.

Modellen instruerades att:

- endast använda det tillhandahållna underlaget,
- inte använda extern information,
- inte anta sådant som saknade stöd,
- prioritera gällande, kundspecifika och auktoritativa källor,
- avstå från en bestämd slutsats när underlaget inte räckte.

Varje test kördes i en separat chatt för att minska risken för kontextläckage mellan tester.

5. Retrieval Run01 – Resultat

Retrieval Run01 testade om ett enkelt textsökningssystem kunde identifiera relevanta dokument i ett kontrollerat corpus innan frågan skickades vidare till språkmodellen.

Testkorpusen bestod av 50 dokument: 18 primärkällor och 32 distraktorer. Distraktorerna inkluderade bland annat äldre policyversioner, ej accepterade utkast, interna anteckningar, historiska kundfall och dokument från andra kunder.

En TF-IDF-baserad retrieval-baseline användes för att rangordna dokumenten. För varje fråga hämtades de fem högst rankade dokumenten. Testet omfattade 15 frågor, G31–G45.

HIT@3	HIT@5	ALL GOLD SOURCES @5	ANSWER PASS
80 %	86,7 %	46,7 %	15/15

Retrieval-resultat

Hit@3: 12/15 (80 %) · Hit@5: 13/15 (86,7 %) · All Gold Sources @5: 7/15 (46,7 %)

Hit@5 visar att minst en relevant gold source fanns bland de fem högst rankade dokumenten i 13 av 15 fall. Det striktare måttet All Gold Sources @5 visar däremot att samtliga källor som bedömts nödvändiga för frågan endast återfanns i 7 av 15 fall.

Skillnaden är betydelsefull eftersom frågor som kräver flera källor kan se lyckade ut enligt traditionell Hit@K trots att en beslutsavgörande källa saknas.

Answer-resultat

PASS	PARTIAL	FAIL	CRITICAL FAILURES
15/15	0	0	0

För varje test skapades därefter en isolerad prompt som endast innehöll frågan och de fem dokument som retrieval-systemet faktiskt hade hämtat. Modellen instruerades att inte använda extern information och att uttryckligen avstå från slutsatser som inte stöddes av underlaget.

Varje fråga kördes i en separat chatt för att minska risken för kontextläckage mellan tester.

I flera tester saknades en eller flera gold sources. I dessa fall kunde modellen i vissa fall fortfarande ge ett korrekt svar från återstående evidens. När avgörande information saknades avstod modellen från att fastställa sådant som underlaget inte stödde.

6. TF-IDF vs Embeddings – Jämförelse

Samma 15 retrieval-frågor och samma corpus med 50 dokument användes för att jämföra TF-IDF-baselines med semantisk embedding-baserad retrieval.

Mått	TF-IDF	Embeddings
Hit@3	12/15 (80 %)	14/15 (93,3 %)
Hit@5	13/15 (86,7 %)	14/15 (93,3 %)
All Gold Sources @5	7/15 (46,7 %)	8/15 (53,3 %)

Embeddings förbättrade retrieval-prestandan på samtliga tre övergripande mått. Den största förbättringen syntes i Hit@3, där resultatet ökade från 80 % till 93,3 %.

Förbättringen var däremot mer begränsad för det striktare måttet All Gold Sources @5. Embedding-retrieval hittade samtliga nödvändiga källor i 8 av 15 fall, jämfört med 7 av 15 för TF-IDF.

Det visar att semantisk likhet förbättrade rankingen av relevanta dokument men inte eliminerade problemen i frågor som krävde flera samtidiga källor, korrekt source authority eller temporal kontext.

Utökad retrieval-jämförelse

Metod	Hit@3	Hit@5	All Gold Sources @5
TF-IDF	80 %	86,7 %	46,7 %
Embeddings	93,3 %	93,3 %	53,3 %
Embeddings + metadata	66,7 %	80 %	40 %
Embeddings + reranking	86,7 %	93,3 %	46,7 %

Två ytterligare retrieval-varianter testades: embedding-retrieval med fasta metadatajusteringar samt embedding-retrieval följt av CrossEncoder-reranking. Ingen av dessa förbättrade den rena embedding-baselines. Metadatareglerna försämrade samtliga övergripande mått, medan reranking behöll Hit@5 men försämrade Hit@3 och All Gold Sources @5.

Resultatet visar att ökad systemkomplexitet inte automatiskt förbättrar retrieval quality. Vidare optimering mot samma testset stoppades för att minska risken för överanpassning.

Representativa fall

G32 – tydlig förbättring

TF-IDF hittade S2 men missade S13. Embeddings hämtade både S2 och S13 inom topp 5 och förbättrade därmed All Gold Sources @5 från No till Yes.

G34 – partiell förbättring

TF-IDF missade både S14 och S15. Embeddings hittade S15 men missade fortfarande S14. Retrieval blev bättre men underlaget var fortfarande ofullständigt.

G41 – olika fel mellan metoderna

TF-IDF hittade S3 och S18 men missade S7. Embeddings hittade S3 och S7 men missade S18. Båda metoderna gav ofullständig evidens, men av olika skäl.

G42 – gemensamt retrieval-fel

Både TF-IDF och embeddings missade den avgörande källan S18 inom topp 5. Fallet visar att ämnesmässigt närliggande dokument kan rankas högre än den källa som faktiskt behövs för korrekt slutsats.

G45 – fler-källretrieval som flaskhals

Båda metoderna missade flera nödvändiga källor. Frågan kräver samtidig hantering av standard-SLA, kundspecifikt avtal, informell intern information, renewal-utkast och senare kundbesked. Detta illustrerar att komplex source-authority reasoning kan begränsas redan i retrieval-steget.

Metodisk observation

Jämförelsen visar att embedding-retrieval förbättrar retrieval quality, men att en bättre embeddingmodell inte automatiskt löser frågor som kräver flera källor.

7. Viktigaste fynd

Run01 visar varför retrieval quality och answer quality bör bedömas separat.

De utökade retrieval-testerna visade också att mer avancerade komponenter inte automatiskt förbättrar kvaliteten. Den rena embedding-baserade retrievalen gav bäst resultat på det aktuella testsetet, medan både fasta metadatajusteringar och CrossEncoder-reranking försämrade minst ett centralt retrieval-mått.

Ett system kan ha ett relativt högt Hit@5 samtidigt som alla beslutsavgörande källor saknas i många frågor. Om endast answer accuracy mäts kan sådana retrievalproblem döljas, särskilt när modellen lyckas kompensera genom försiktig inferens eller korrekt abstention.

Testet visar också värdet av att skilja mellan:

1	någon relevant källa hittades,
2	alla nödvändiga källor hittades,
3	modellen kunde svara korrekt från det hämtade underlaget,
4	modellen avstod korrekt när evidensen inte räckte.

8. Begränsningar

EVALGRÄNS · KONTROLLERAT PORTFOLIO-CASE

Detta är en kontrollerad eval och inte ett produktionstest av ett fullständigt RAG-system.

Testet omfattar TF-IDF-baserad retrieval, lokal embedding-baserad retrieval, en enkel metadatajusterad variant samt embedding-retrieval med CrossEncoder-reranking över ett litet, manuellt konstruerat corpus. Det omfattar däremot inte produktionsmässig vector database, dokumentchunking, avancerad metadatafiltrering, access control eller retrieval över stora dokumentmängder.

Resultaten beskriver därför endast beteendet i denna specifika evalkörning och ska inte tolkas som generell modellprestanda eller som en uppskattning av produktionsprestanda.