

AI Quality & Evaluation – Portfolio Overview

Praktisk evaluation av retrieval, source authority, temporal context och dokumentgrundade AI-svar

FOKUS AI Quality & Evaluation	PORTFOLIO 2 genomförda evalcase
TEKNISK NIVÅ Praktisk eval + grundläggande retrieval/Python	STATUS Aktiv kompetensutveckling

Snabb översikt

GOLDEN SET 45 frågor	RETRIEVAL CORPUS 50 dokument	RETRIEVAL-METODER 4
BÄSTA HIT@5 93,3 %	ANSWER EVAL (TF-IDF) 15/15 PASS	CRITICAL FAILURES 0

1. Profil

Jag arbetar med AI quality och evaluation med särskilt fokus på hur AI-system hittar, prioriterar och använder information från dokument och förändrad kontext över tid.

Min styrka ligger i att identifiera fel som inte alltid är rena faktafel. Ett svar kan innehålla korrekt information men ändå vara fel därför att informationen är gammal, gäller fel kund, kommer från en svagare källa, beskriver ett förslag i stället för ett beslut eller används utanför sitt ursprungliga sammanhang.

Jag har omfattande praktisk erfarenhet av generativ AI och bygger successivt mer formell evalkompetens genom reproducerbara testfall, golden sets, retrieval-mätning, isolerade answer-tests och dokumenterad felanalys.

2. Fokusområden

Retrieval quality Om rätt och tillräckligt underlag hämtas innan modellen svarar.	Source authority Om systemet skiljer mellan gällande policy, kundavtal, utkast, prognos och informell anteckning.
Temporal context Hur äldre och nyare information vägs mot varandra.	Discussed vs decided Att diskussioner, prognoser, förslag och faktiska beslut hålls isär.
Cross-context boundaries Att information från olika kunder, projekt eller situationer inte blandas samman.	Abstention & insufficient evidence Om modellen avstår från en för säker slutsats när avgörande information saknas.

3. Portfolio-case

EVALCASE 02 Retrieval & Temporal Context Kontrollerat portfolio-case som separerade retrieval från answer generation i ett simulerat historiskt informationsunderlag och testade temporal och kontextuell informationsanvändning. Retrieval 8/8 Answer 8/8 Stale retrieval 0 Kritiska fel 0
--

EVALCASE 03

Golden Set, Retrieval & Error Analysis

Utvecklade metodiken till en teknisk retrieval-evaluation med 45 frågor i Golden Set, 50 dokument i corpus och fyra retrieval-varianter på samma testfrågor.

BÄSTA HIT@5	ALL GOLD @5	ANSWER EVAL	CRITICAL FAILURES
93,3 %	53,3 %	15/15 PASS	0

Rena embeddings gav bäst samlat retrievalutfall i det aktuella testsetet. Metadatajustering och CrossEncoder-reranking förbättrade inte baselinen, och vidare optimering mot samma testset stoppades för att minska risken för överanpassning.

4. Metoder och verktyg

EVALMETOD	TEKNIK
Golden sets	Python och pandas
Gold sources	scikit-learn
Error classification	TF-IDF och cosine similarity
PASS / PARTIAL / FAIL	Embeddings / SentenceTransformers
Critical failures	CrossEncoder-reranking
Isolerade testkörningar	Hit@3 / Hit@5
Error analysis	All Gold Sources @5

5. Vad arbetsproven demonstrerar

Portfolion visar en arbetsprocess där ett kvalitativt AI-problem formaliseras till kontrollerbara testfall, mätbara retrievalresultat och dokumenterad felanalys.

Problem → Testhypotes → Testdata → Retrieval → Metrics → Answer evaluation → Error analysis → Slutsats

6. Nuvarande kompetensnivå

Min främsta kompetens ligger idag i praktisk AI-evaluation, modellbeteende, dokument- och kontextanalys samt konstruktion av kontrollerade testfall. Jag bygger samtidigt teknisk grundkompetens för att kunna genomföra fler delar av evalarbetet självständigt.

Jag beskriver mig inte som ML-engineer eller specialist på produktions-RAG. Den tekniska erfarenheten är fortfarande under utveckling, medan den praktiska erfarenheten av att analysera subtila modell-, kontext- och informationsfel är betydligt mer omfattande.

7. Nästa utvecklingsområden

API-baserade evalflöden	Regressionstester
Större oberoende testset	Mer systematisk statistik
Verkliga RAG-system	Vector databases / chunking / access control

Portfolio-case: Evalcase 02 – Retrieval & Temporal Context | Evalcase 03 – Golden Set, Retrieval & Error Analysis